





Panda UFSCar



Classificação binária - Spam ou não Spam?

Regressão Logística



Objetivos da Semana

- Entender o que é **classificação binária**
- Diferenciar **regressão linear** (semana passada) de **regressão logística** (hoje)
- Aprender o que é a função **sigmoide** (de forma intuitiva)
- Conhecer a **matriz de confusão** e as métricas: acurácia, precisão e recall
- Ver um exemplo prático: **classificar e-mails como spam ou não spam**



Lembrando da semana passada

	Regressão Linear
O que faz	Prever números contínuos
Exemplo	Preço de uma casa (R\$ 350.000,00)
Pergunta que responde	Quanto?
Saída	Qualquer número (ex: 0 a 1 milhão)


Problema: E se a gente quiser responder uma pergunta do tipo SIM ou NÃO?

Problemas de classificação no dia a dia



Pergunta	Resposta possível
Este e-mail é spam?	Sim / Não
Este tumor é maligno?	Sim / Não
Este cliente vai comprar o produto?	Sim / Não
Esta transação é fraudulenta?	Sim / Não
Este aluno vai passar na disciplina?	Sim / Não

Todos esses problemas têm uma resposta binária (duas categorias).



Mas por que "regressão" se é classificação?

A regressão logística não prevê 0 ou 1 diretamente. Ela prevê uma probabilidade entre 0 e 1.

- Probabilidade próxima de 1 → classe "Sim" (ex: spam)
- Probabilidade próxima de 0 → classe "Não" (ex: não spam)

Exemplo: O modelo pode dizer: "Este e-mail tem 92% de chance de ser spam". Aí a gente define um limite (geralmente 0,5 ou 50%) para decidir.

Probabilidade	Decisão (limite = 0,5)
0,92 (92%)	Spam
0,18 (18%)	Não Spam



A função Sigmoid

Problema: A regressão linear pode gerar números negativos ou muito altos (ex: -100, 500). Mas probabilidade precisa estar entre 0 e 1.

Solução: A função Sigmoid (curva em forma de "S")

Interpretação intuitiva:

- Valores muito negativos $\rightarrow$ perto de 0
- Valores muito positivos $\rightarrow$ perto de 1
- Na metade (0) $\rightarrow$ exatamente 0,5 (50%)

Vocês não precisam decorar a fórmula. O importante é entender que a sigmoide comprime qualquer número para um valor entre 0 e 1.



Regressão Linear vs Logística

	Regressão Linear	Regressão Logística
Tipo de problema	Regressão	Classificação binária
Saída	Número contínuo (ex: 350.000)	Probabilidade entre 0 e 1
Pergunta	Quanto?	Sim ou Não?
Função usada	Reta linear	Sigmoide
Exemplo	Preço da casa	E-mail é spam?

Como avaliar um classificador?

Quando o modelo faz uma previsão, ela pode estar certa ou errada de 4 formas diferentes:

	Previsto: Sim	Previsto: Não
Real: Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real: Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Exemplo (spam):

- **VP:** Modelo disse SPAM, e era SPAM ✓ (acertou)
- **FN:** Modelo disse NÃO SPAM, mas era SPAM ✗ (errou feio – e-mail importante foi para o lixo)
- **FP:** Modelo disse SPAM, mas NÃO ERA SPAM ✗ (inconveniente – e-mail bom foi para o spam)
- **VN:** Modelo disse NÃO SPAM, e não era spam ✓ (acertou)

Métricas a partir da matriz de confusão

Métrica	Fórmula	O que significa	Pergunta que responde
Acurácia	$(VP + VN) / \text{Total}$	Percentual total de acertos	De todas as previsões, quantas acertamos?
Precisão	$VP / (VP + FP)$	Dos que foram previstos SIM, quantos realmente eram SIM?	Quando o modelo diz SIM, podemos confiar?
Recall	$VP / (VP + FN)$	Dos que eram SIM, quantos foram detectados?	O modelo está pegando todos os SIMs?

Exemplo prático (spam):

- Acurácia alta = modelo acerta a maioria das classificações
- Precisão alta = quando o modelo diz "spam", é spam mesmo (poucos falsos positivos)
- Recall alto = o modelo está pegando quase todos os spams (poucos falsos negativos)

Dependendo do problema, a gente prioriza uma métrica diferente!

Quando priorizar cada métrica?

Problema	Métrica mais importante	Por quê?
Diagnóstico de câncer	Recall (alto)	É pior dizer que a pessoa não tem câncer (FN) do que dizer que tem e depois investigar (FP)
Filtro de spam	Precisão (alta)	É pior um e-mail importante ir para o spam (FP) do que um spam cair na caixa de entrada (FN)
Modelo equilibrado	Acurácia	Quando os dois tipos de erro têm custo similar

Exemplo prático



Dataset: E-mails com palavras como "ganhe", "prêmio", "urgente", "dinheiro", etc.

O que vocês vão fazer em casa:

```
# Importar bibliotecas
import pandas as pd
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, precision_score, recall_score,
confusion_matrix
```

```
# Carregar dados
df = pd.read_csv('emails.csv')
X = df[['palavras_spam']] # exemplo simplificado
y = df['spam'] # 1 = spam, 0 = não spam
```

```
# Dividir treino/teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2)
```

```
# Treinar modelo
modelo = LogisticRegression()
modelo.fit(X_treino, y_treino)
```

```
# Prever e avaliar
predicoes = modelo.predict(X_teste)
print(f'Acurácia: {accuracy_score(y_teste, predicoes)}')
print(f'Precisão: {precision_score(y_teste, predicoes)}')
print(f'Recall: {recall_score(y_teste, predicoes)}')
print('Matriz de Confusão:')
print(confusion_matrix(y_teste, predicoes))
```


Interpretando os resultados

Resultado	Interpretação
Acurácia = 0,95	O modelo acertou 95% das classificações
Precisão = 0,92	Quando o modelo disse "spam", 92% das vezes realmente era spam
Recall = 0,88	O modelo identificou 88% de todos os spams que existiam

Matriz de confusão exemplo:

	Previsto: Spam	Previsto: Não Spam
Real: Spam	90 (VP)	10 (FN)
Real: Não Spam	5 (FP)	95 (VN)

Discussão: Dependendo da aplicação, esses números podem ser bons ou ruins!

Resumo da Semana


- Regressão Logística = classificação binária (Sim/Não)
- Ela prevê probabilidades entre 0 e 1 usando a função Sigmoid
- Diferença principal da regressão linear: saída é probabilidade, não número contínuo
- Matriz de confusão organiza os acertos e erros em 4 categorias
- Métricas: Acurácia (total de acertos), Precisão (confiança no SIM), Recall (capacidade de detectar SIMs)
- Cada problema exige uma métrica prioritária diferente

Para fazer em casa

Objetivo: Implementar um classificador de spam e entender as métricas de avaliação.



Instruções:

1. Baixar o notebook exemplo disponível no repositório
2. Executar o código de regressão logística (dataset de e-mails)
3. **Testar mudanças:**
 - Alterar a proporção de treino/teste
 - Mudar o limite de decisão (se quiser testar)
4. **Responder no notebook:**
 - Qual foi a acurácia, precisão e recall obtidos?
 - O que cada métrica significa neste contexto (spam)?
 - Para um filtro de spam, qual métrica você acha mais importante? Por quê?
5. Subir o notebook respondido na pasta da semana 10 do repositório



Links úteis

- [Documentação Scikit-learn – Regressão Logística](#)
- [Matriz de confusão – Explicação visual](#)
- [Dataset de spam exemplo \(Kaggle\)](#)



Panda UFSCar

Obrigada!