


2026



ÁRVORES DE DECISÃO E RANDOM FOREST



Modelos interpretáveis e o poder do
“aprendizado em conjunto”



Objetivos da Semana

O que vamos aprender hoje?

- Entender o conceito de Árvore de Decisão de forma visual e intuitiva
- Aprender como uma árvore "decide" passo a passo
- Conhecer as vantagens e desvantagens desse modelo
- Entender o que é Random Forest e por que ele é mais poderoso
- Comparar árvore de decisão com regressão logística (semana passada)



O que é uma Árvore de Decisão?

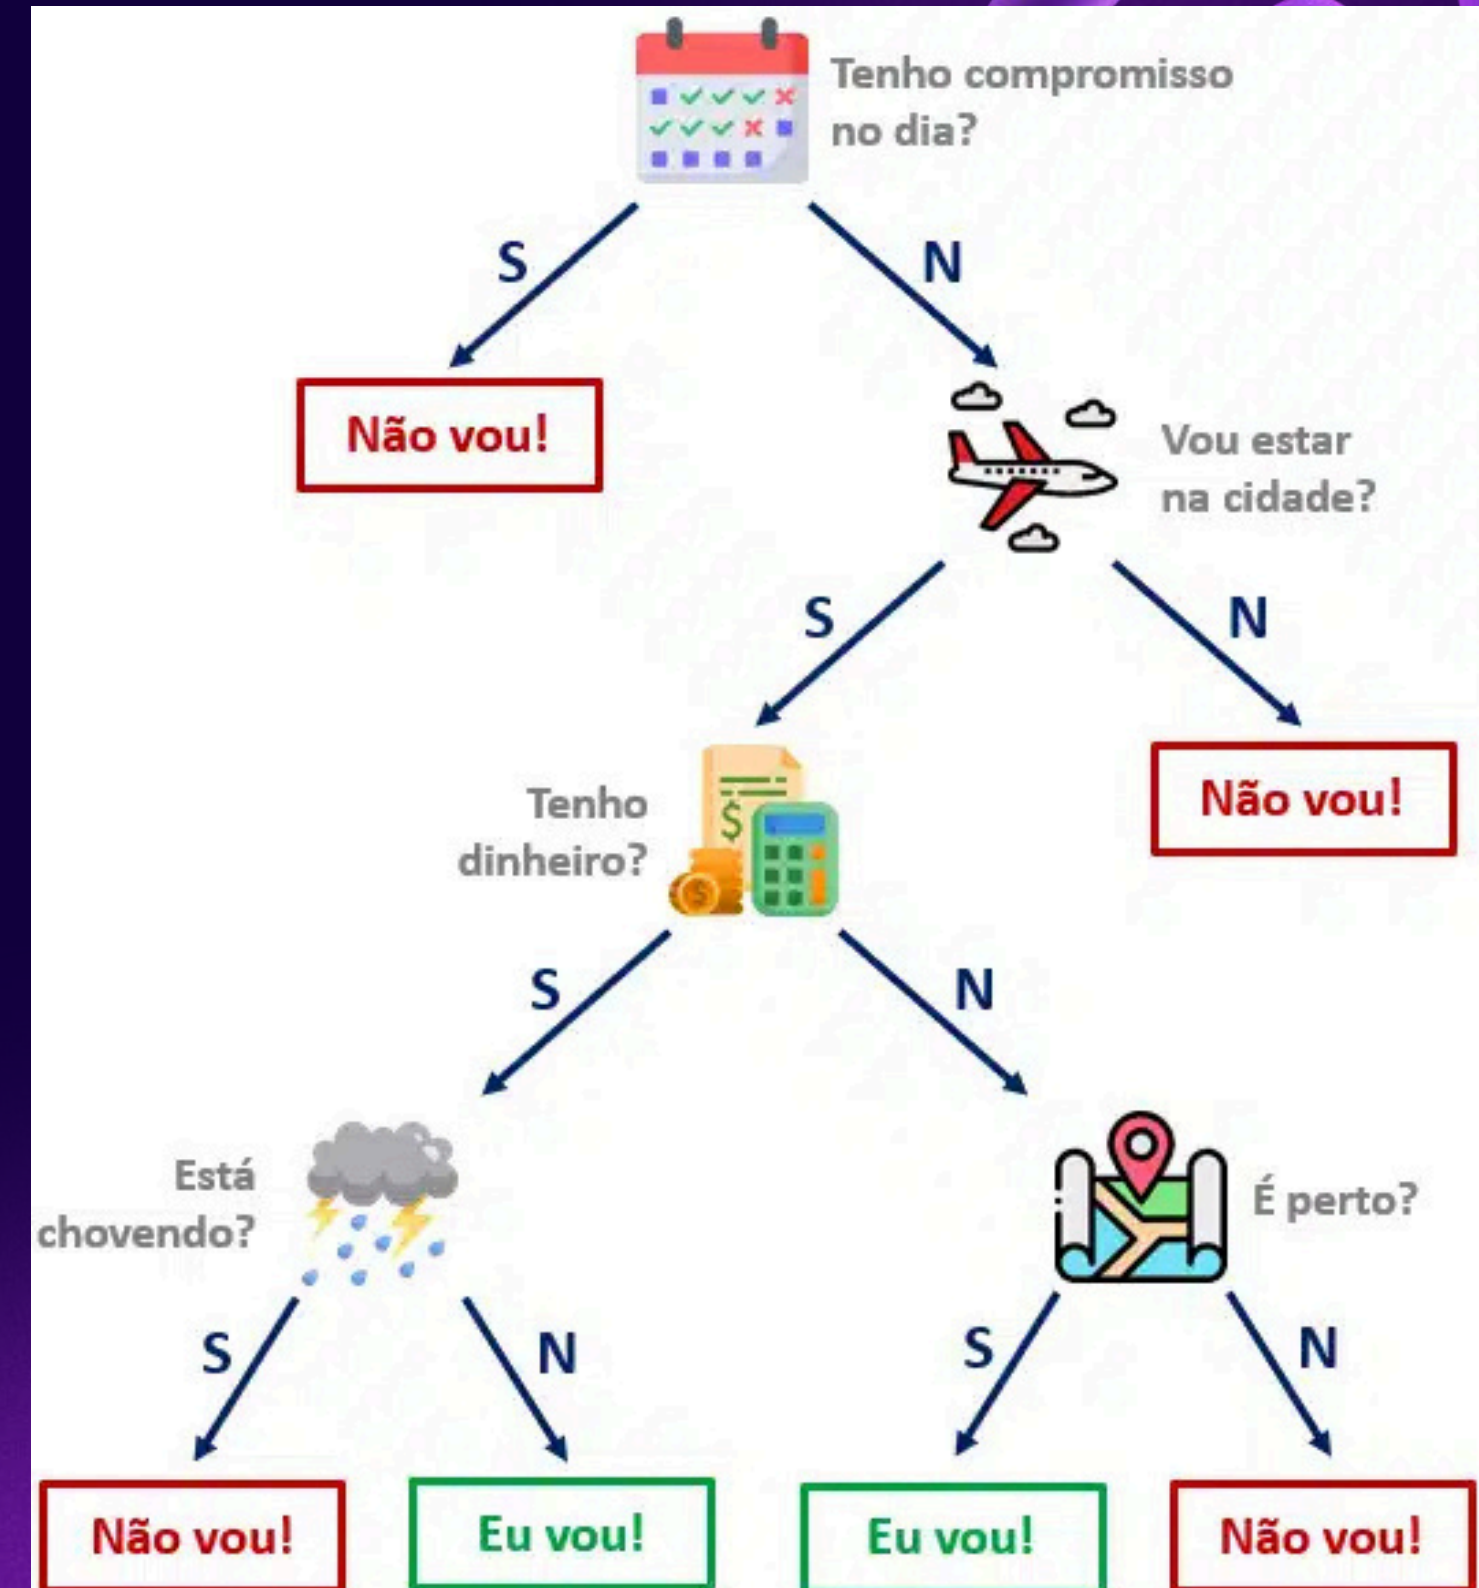
Um modelo que imita o raciocínio humano

"Uma Árvore de Decisão é exatamente o que o nome sugere: uma árvore onde cada 'galho' representa uma decisão, e cada 'folha' representa um resultado."

Exemplo do dia a dia (fora do ML):

"Você quer sair para fazer uma caminhada. Como decide?"

É assim que a gente pensa no dia a dia: fazendo perguntas e seguindo caminhos diferentes dependendo das respostas.



Árvore de Decisão em Machine Learning

Funciona do mesmo jeito, mas com dados

No ML, a árvore aprende sozinha:

- Quais perguntas fazer?
- Em que ordem fazer essas perguntas?
- Onde cortar os valores?

Exemplo com dados (crédito):

- Renda > R\$ 5.000? → Sim → Aprovar crédito
- Renda > R\$ 5.000? → Não → Histórico bom? → Sim → Aprovar com limite menor
- Renda > R\$ 5.000? → Não → Histórico bom? → Não → Recusar

"O modelo olha para os dados e encontra os melhores 'cortes' para separar as classes."

Como a árvore decide?

O processo de construção
– de forma simples

Passo a passo intuitivo:

1. O algoritmo olha para todas as variáveis disponíveis
2. Para cada variável, ele testa vários pontos de corte
3. Ele escolhe o corte que separa melhor as classes (ex: Spam vs Não Spam)
4. Repete o processo dentro de cada "galho" (subgrupo)
5. Para quando atingir um critério de parada (ex: profundidade máxima)

Exemplo:

Se a variável "palavra 'ganhe'" separa bem os spams, essa será a primeira pergunta no topo da árvore.

A árvore vai ficando cada vez mais específica. No topo, decisões mais gerais. Nas folhas, decisões muito específicas.

Vantagens da Árvore de Decisão

Por que usar árvores?

Vantagem	Explicação
Fácil de interpretar	Dá para explicar para um chefe ou cliente que não sabe ML
Não precisa escalar dados	Diferente da regressão, não precisa normalizar números
Lida com dados mistos	Números e categorias juntos? Sem problema
Visualização simples	Dá para desenhar a árvore e ver como ela decide

Essa interpretabilidade é a maior vantagem. Enquanto a regressão logística te dá um número mágico, a árvore te mostra o caminho das decisões.

Desvantagens da Árvore de Decisão



Desvantagem	Explicação
Overfitting	A árvore pode decorar os dados de treino e não generalizar
Instabilidade	Uma pequena mudança nos dados pode criar uma árvore completamente diferente
Pode ficar gigante	Se não controlarmos, a árvore cresce até ter uma folha para cada exemplo
Tendenciosa	Pode favorecer variáveis com muitos valores possíveis

O overfitting é o problema mais sério. Uma árvore muito profunda pode decorar os dados de treino perfeitamente, mas vai se sair mal em dados novos.



Como controlar o overfitting?

Podando a árvore (pruning)

Técnica	O que faz
Limitar profundidade máxima	Impede a árvore de crescer demais
Número mínimo por folha	Exige um número mínimo de exemplos em cada folha
Número mínimo por divisão	Só divide se o nó tiver pelo menos X exemplos
Poda (pruning)	Remove galhos que não trazem benefício significativo

É como podar uma árvore de verdade: você corta galhos que não estão saudáveis para a planta crescer melhor. No ML, a gente 'poda' a árvore para ela não decorar os dados.

Introdução ao Random Forest

Uma árvore é boa. Várias árvores juntas são melhores.

O conceito do Random Forest:

"Random Forest = Floresta Aleatória. Ou seja: muitas árvores de decisão trabalhando juntas."

Como funciona:

1. Criamos várias árvores (ex: 100 árvores)
2. Cada árvore é treinada com uma **amostra diferente** dos dados
3. Cada árvore considera apenas um **subconjunto aleatório** das variáveis
4. Para fazer uma previsão, todas as árvores "**votam**"
5. A classe que receber mais votos é a vencedora

Por que Random Forest é melhor?

Sabedoria das multidões aplicada ao ML

Vantagem	Explicação
Reduz overfitting	Erros de uma árvore são corrigidos pelas outras
Mais estável	Mudar um pouquinho os dados não bagunça o resultado
Muito preciso	Geralmente é um dos melhores modelos para dados tabulares
Mantém interpretabilidade parcial	Dá para ver quais variáveis são mais importantes

Uma árvore sozinha pode ser instável. Mas se você pegar 100 árvores e juntar os votos delas, o resultado fica muito mais robusto. É o princípio da 'sabedoria das multidões'.

Comparação com Regressão Logística

	Regressão Logística	Árvore/Random Forest
Interpretabilidade	Alta (coeficientes)	Muito alta (árvore individual)
Precisão típica	Boa	Geralmente melhor
Escala de dados	Baixo (se regularizada)	Pode overfitar (floresta reduz)
Tendenciosa	Precisa escalar	Não precisa
Relações complexas	Captura só relações lineares	Captura relações complexas
Tempo de treino	Rápido	Pode ser lento (muitas árvores)

Não existe melhor em absoluto. Regressão logística é ótima para problemas lineares e quando você precisa explicar cada coeficiente. Random Forest é melhor para dados complexos e quando a precisão é a prioridade.

Exemplo prático

Classificação de clientes – Quem vai comprar?

Problema: Prever se um cliente vai comprar um produto com base em:

- Idade
- Renda
- Histórico de compras anteriores
- Tempo desde a última compra

O que o código faz (em resumo):



Etapa	O que acontece
1	Carrega os dados dos clientes
2	Divide os dados em treino (80%) e teste (20%)
3	Cria uma Árvore de Decisão e treina
4	Cria uma Random Forest com 100 árvores e treina
5	Compara a acurácia dos dois modelos
6	Mostra qual modelo teve melhor desempenho

O código completo está no **repositório** da semana 11. Vocês vão baixar, executar e comparar os resultados.

O que esperar da comparação

O que vocês vão observar?

Cenário	O que significa
Floresta muito melhor que árvore	A árvore sozinha estava overfitando ou instável
Floresta levemente melhor	Floresta ajuda, mas o problema não é muito complexo
Resultados parecidos	O problema é simples ou os dados são muito limpos

Em geral, a Random Forest não fica pior do que a árvore individual. No pior dos casos, ela empata.


Pergunta para responder no notebook:

"Para este problema de prever compra de clientes, qual modelo você escolheria e por quê?"

Resumo da Semana

Recapitulando

- Árvore de Decisão = modelo que faz perguntas em sequência, como um fluxograma
- É interpretável – dá para explicar cada decisão
- Principais desvantagens: overfitting e instabilidade
- Random Forest = várias árvores trabalhando juntas
- Cada árvore vota, a classe mais votada vence
- Floresta resolve os problemas da árvore única: reduz overfitting e aumenta estabilidade
- Em geral, Random Forest é mais precisa que uma única árvore



Atividade para casa

Objetivo: Implementar e comparar Árvore de Decisão vs Random Forest.

Instruções:

1. Baixar o notebook exemplo disponível no repositório
2. Executar o código (dataset de clientes)
3. Testar mudanças:
 - Alterar a profundidade máxima da árvore (max_depth)
 - Alterar o número de árvores na floresta (n_estimators)
4. Responder no notebook:
 - Qual modelo teve melhor acurácia? A diferença é grande?
 - O que aconteceu quando você aumentou a profundidade da árvore?
 - Para este problema, qual modelo você escolheria e por quê?
5. Subir o notebook respondido na pasta da semana 11 do repositório

Referências

Links úteis

- [Documentação Decision Tree – Scikit-learn](#)
- [Documentação Random Forest – Scikit-learn](#)
- [Visualização interativa de Árvores de Decisão](#)