





2026

Validação e Otimização de Modelos



CROSS-VALIDATION, GRIDSEARCH E COMO
EVITAR OVERFITTING

GRUPO DE ESTUDO DE MACHINE LEARNING - PANDA
UFSCAR



Objetivos da Semana

O QUE VAMOS APRENDER HOJE?

- Entender o conceito de Overfitting (e por que ele é um problema)
- Aprender o que é Cross-Validation (validação cruzada) e por que ela é melhor que um único train-test split
- Conhecer o GridSearch – como encontrar os melhores hiperparâmetros de forma automática
- Ver como evitar overfitting na prática
- Entender o fluxo completo: dados → pré-processamento → validação → otimização → modelo final



Revisão Rápida

Etapa	O que fazemos
1. Coletar dados	Pegar os dados brutos
2. Pré-processar	Tratar nulos, escalonar, codificar
3. Dividir treino/teste	80% treino, 20% teste
4. Treinar modelo	Ensinar o modelo com os dados de treino
5. Avaliar	Testar com dados que o modelo nunca viu

Mas será que isso é suficiente? O que acontece se a divisão treino/teste for "azarada"? Ou se o modelo simplesmente "decorou" os dados de treino?
É aqui que entram a Cross-Validation e o GridSearch!

O vilão do Machine Learning

O QUE É OVERFITTING?

Definição: Quando o modelo aprende "de cor" os dados de treino, mas não consegue generalizar para dados novos.

Analogia: É como um aluno que decora as respostas da prova, mas não entende a matéria. Na prova ele vai bem, mas na vida real ele não consegue aplicar o conhecimento.

	Modelo Bom	Modelo com Overfitting
Desempenho no treino	Bom (ex: 85%)	Excelente (ex: 99%)
Desempenho no teste	Bom (ex: 82%)	Ruim (ex: 60%)
Consegue generalizar?	✓ Sim	✗ Não


Como identificar Overfitting?

SINAIS DE QUE SEU MODELO ESTÁ OVERFITADO

1. Acurácia no treino muito alta (ex: 99%) e acurácia no teste muito baixa (ex: 60%)
2. O modelo funciona bem nos dados que você usou para treinar, mas falha miseravelmente em dados novos
3. O modelo é muito complexo para a quantidade de dados que você tem

Exemplo: Se você tem 100 amostras e usa um modelo com 1000 parâmetros, é quase certeza de overfitting.

A solução? **Validar o modelo de forma mais robusta e controlar a complexidade.**




Cross-Validation – O que é?

CROSS-VALIDATION (VALIDAÇÃO CRUZADA)

Problema do train-test split único: A divisão pode ser "azarada" – pegar um grupo de teste que não representa bem a realidade.

Solução: Fazer várias divisões diferentes e tirar uma média dos resultados.

Cross-Validation 5-fold (5 dobras):



Por que usar Cross-Validation?

VANTAGENS DA CROSS-VALIDATION

Vantagem	Explicação
Mais confiável	Uma única divisão pode ser enganosa. A média de várias é mais estável
Usa todos os dados	Cada dado é usado tanto para treino quanto para teste (em dobras diferentes)
Menos overfitting	O modelo é avaliado em diferentes conjuntos, forçando a generalização
Escolha de modelo	Permite comparar diferentes modelos de forma justa

Exemplo: Se você fizer uma única divisão e der "azar" de pegar um teste muito fácil, sua acurácia pode ser falsamente alta. A Cross-Validation evita isso.

Cross-Validation na prática

COMO USAR NO CÓDIGO (ESTUDO EM CASA)

Interpretação:

- Se as 5 acurácias forem parecidas → modelo está estável
- Se forem muito diferentes → modelo é instável ou os dados são muito heterogêneos

```
from sklearn.model_selection import cross_val_score
from sklearn.linear_model import LogisticRegression

modelo = LogisticRegression()

# Cross-Validation 5-fold
scores = cross_val_score(modelo, X, y, cv=5)

print(f'Acurácias: {scores}')
print(f'Média: {scores.mean():.2f}')
print(f'Desvio padrão: {scores.std():.2f}')
```

Hiperparâmetros vs Parâmetros

QUAL A DIFERENÇA?

	Parâmetros	Hiperparâmetros
O que são	Aprendidos pelo modelo durante o treino	Definidos por nós antes do treino
Exemplo (Árvore de Decisão)	Quais variáveis são usadas em cada nó	Profundidade máxima da árvore
Exemplo (Regressão Logística)	Pesos de cada variável	Força de regularização (C)
Como ajustar?	Automaticamente (.fit())	Manualmente ou com GridSearch

Analogia: Um professor que define as regras do jogo (hiperparâmetros) e os alunos que aprendem o conteúdo (parâmetros).

O que é GridSearch?

GRIDSEARCH - ENCONTRANDO OS MELHORES HIPERPARÂMETROS

Problema: Cada modelo tem hiperparâmetros que afetam o desempenho. Como saber quais usar?

Solução: Testar todas as combinações possíveis de hiperparâmetros e ver qual dá o melhor resultado.

Exemplo (Árvore de Decisão):

Hiperparâmetro	Valores a testar
max_depth (profundidade)	3, 5, 10, 15
min_samples_split	2, 5, 10

Combinações: $4 \times 3 = 12$ combinações diferentes!

O GridSearch testa cada uma, avalia com Cross-Validation e retorna a melhor combinação.

GridSearch com Cross-Validation

A COMBINAÇÃO PODEROSA – GRIDSEARCH + CROSS-VALIDATION

Passo a passo:

Para cada combinação de hiperparâmetros:

1. Executa Cross-Validation (ex: 5 folds)
2. Calcula a média da acurácia
3. Guarda o resultado

Depois de testar todas as combinações:

→ Escolhe a combinação com a melhor média

Isso garante que a escolha dos hiperparâmetros é **robusta** e não depende de uma divisão de dados específica.

Em código (estudo em casa):

```
from sklearn.model_selection import GridSearchCV
from sklearn.tree import DecisionTreeClassifier

param_grid = {
    'max_depth': [3, 5, 10, 15],
    'min_samples_split': [2, 5, 10]
}

modelo = DecisionTreeClassifier()
grid = GridSearchCV(modelo, param_grid, cv=5)
grid.fit(X_treino, y_treino)

print(f'Melhores parâmetros: {grid.best_params_}')
print(f'Melhor acurácia média: {grid.best_score_:.2f}')
```


Como evitar Overfitting

Estratégia	Como funciona
Mais dados	Quanto mais dados, menos chance de decorar padrões específicos
Regularização	Penaliza modelos muito complexos (ex: parâmetro C na regressão logística)
Simplificar o modelo	Usar um modelo menos complexo (ex: árvores rasas em vez de profundas)
Feature selection	Usar apenas as variáveis mais importantes
Early stopping	Parar o treino antes que o modelo decore os dados (em redes neurais, por exemplo)


A mais importante para a gente agora é: use Cross-Validation para validar e GridSearch para escolher hiperparâmetros!

O fluxo completo com validação

FLUXO COMPLETO DE UM PROJETO DE ML (COM VALIDAÇÃO)



Importante: O conjunto de teste só é usado uma vez – no final. Se você usar ele várias vezes para ajustar, ele deixa de ser um teste justo.



Exemplo prático

TITANIC – OTIMIZANDO COM GRIDSEARCH

Dataset: Titanic (já conhecido da semana passada)

O que vocês vão fazer em casa:

1. Aplicar GridSearch em um modelo (Árvore de Decisão)
2. Testar diferentes combinações de hiperparâmetros:
 - `max_depth`: 3, 5, 10, 15
 - `min_samples_split`: 2, 5, 10
 - `criterion`: 'gini', 'entropy'
3. Comparar o resultado do modelo otimizado com o modelo padrão (sem ajuste)
4. Analisar se a otimização realmente melhorou o desempenho

Experimentos para fazer

DEPOIS QUE RODAREM O CÓDIGO BASE, TENTEM:


Experimento	Pergunta para responder
Mudar o número de folds no CV (cv=3, cv=10)	O resultado muda muito?
Testar com outro modelo (Regressão Logística)	O GridSearch melhora os dois?
Usar mais hiperparâmetros no GridSearch	Compensa testar mais combinações?
Usar um modelo simples (sem GridSearch) vs com GridSearch	Qual é a diferença na acurácia?

O importante é observar e comparar. A prática de experimentar é o que mais ensina.

Resumo da Semana

RECAPITULANDO

- Overfitting = modelo decora os dados de treino e não generaliza
- Cross-Validation = várias divisões treino/teste → resultado mais confiável
- GridSearch = testa todas as combinações de hiperparâmetros para achar a melhor
- GridSearch + Cross-Validation = a combinação mais poderosa para escolher modelos
- Estratégias para evitar overfitting: mais dados, regularização, simplificar modelo
- O conjunto de teste só é usado uma vez, no final




Para fazer em casa

Objetivo: Aplicar GridSearch e Cross-Validation em um modelo do Titanic.

Instruções:

1. Baixar o notebook exemplo do repositório
2. Executar o código completo
3. Testar as mudanças sugeridas no Slide 15
4. **Responder no notebook:**
 - Quais foram os melhores hiperparâmetros encontrados?
 - O modelo otimizado teve uma acurácia melhor que o modelo padrão? Quanto?
 - O que aconteceu quando você mudou o número de folds no Cross-Validation?
 - Você acha que o GridSearch compensa o tempo de processamento? Por quê?
5. Subir o notebook respondido na pasta da semana 13 do repositório



Referências

LINKS ÚTEIS

- [Documentação Scikit-learn – Cross-Validation](#)
- [Documentação Scikit-learn – GridSearchCV](#)



Obrigada!

PANDA UFSCAR